Pipeline Híbrido para Análise da Alfabetização no Brasil

GRUPO

Henrique Carvalho Brod

Nathalia Vilas Boas

Iuri de Jesus Martins

Patrícia Terezinha Marques Borba

ESTRUTURA

O QUE VAMOS APRESENTAR

01 **Contexto e motivação**
Compromisso Nacional e o desafio da alfabetização infantil

02 **Arquitetura de dados**
Pipeline Medalhão (Bronze, Silver e Gold) em BigQuery

03 **Fontes e governança**
7 tabelas da Base dos Dados, pesos amostrais e armadilhas

04 **Qualidade e resiliência**
Regras bloqueantes, Circuit Breaker e alertas por e-mail

05 **Análise de resultados**
Evolução do Brasil (2023–2025) e metas pactuadas

06 **Prova dos nove**
Validação cruzada de microdados versus indicadores oficiais

07 **Panorama municipal**
Cumprimento de metas e desigualdade regional nas UFs

08 **Aplicação em IA**
Base de features (Fase 3), streaming e FinOps de produção

09 **Conclusão e impacto prático**
Transformando dados em ação para a alfabetização

01 CONTEXTO E MOTIVAÇÃO

O DESAFIO DA ALFABETIZAÇÃO

O PROBLEMA

Gestões que dependem de planilhas dispersas e relatórios estáticos identificam deficiências tarde demais. O Compromisso Nacional Criança Alfabetizada exige visibilidade imediata do aprendizado real.

A SOLUÇÃO

Pipeline híbrido e automatizado que cruza indicadores do INEP, com dados oficiais em lote e streaming simulado. Audita o indicador oficial de 743 pontos no Saeb e antecipa o cumprimento de metas.

3,9 MILHÕES
registros de alunos analisados

7 TABELAS
unificadas da Base dos Dados

80% EM 2030
meta pactuada nacional da rede pública

3 ANOS
de série histórica (2023, 2024 e 2025)

02 ARQUITETURA DE DADOS

3 CAMADAS

BRONZE / RAW

Ingestão bruta e linhagem preservada

Python + BigQuery Sandbox + Parquet. Cópia bruta das 7 tabelas do INEP, append-only, particionada por data de ingestão (_source_table, _record_hash).

SILVER / ENRIQUECIDA

Sanitização, tipagem e regras bloqueantes

Python e Pandas. Nulos preservados (sem preencher com zero) e Circuit Breaker: chaves íntegras, UFs válidas, taxas de 0 a 100.

GOLD / CONSUMO

Agregações analíticas e inteligência

Streaming simulado integrado, metas municipais, estaduais e nacionais, Prova dos Nove, cenários para 2030 e base de features para IA.

7 TABELAS DA BASE DOS DADOS

MUNICÍPIO E UF

Tabelas territoriais

municipio e uf: chaves geográficas oficiais e códigos de 7 dígitos.

ALUNOS E AVALIAÇÃO

Microdados de proficiência

alunos (~3,9 mi): pesos amostrais, notas e presença para a Prova dos Nove.

METAS NACIONAIS E ESTADUAIS

Trajetórias pactuadas

meta_alfabetizacao_brasil e _uf: metas anuais e 80% em 2030.

METAS MUNICIPAIS

Metas por localidade

meta_alfabetizacao_municipio: audita cada cidade e isola as sem meta.

DICIONÁRIO

Padronização de códigos

dicionario: mapeia códigos de rede e status de preenchimento.

Pesos amostrais e códigos brutos são as principais armadilhas: tratados antes de qualquer agregação.

04 GOVERNANÇA E RESILIÊNCIA

DADO RUIM NÃO PASSA

O sistema não assume que a fonte é perfeita: valida cada etapa e interrompe o fluxo se houver inconsistência.

REGRAS BLOQUEANTES

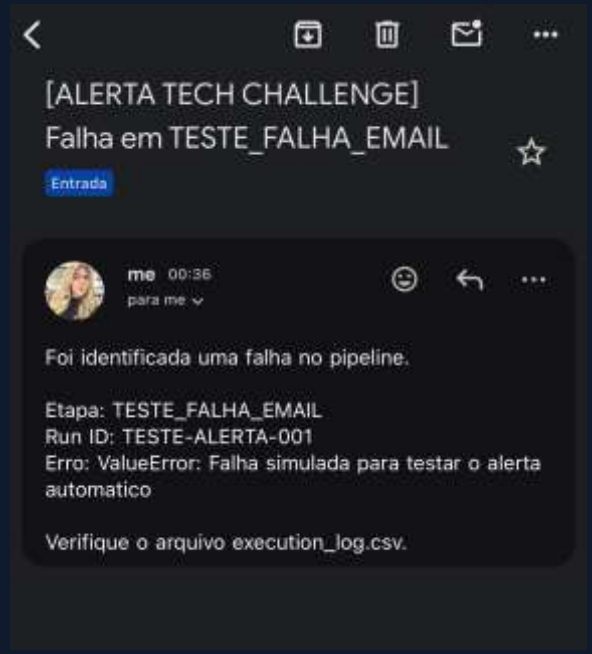
O CIRCUIT BREAKER

Na Silver, antes da Gold: chaves duplicadas, códigos fora do dicionário, UFs inválidas ou taxas fora de 0–100 reprovam o lote e disparam FalhaQualidadeBloqueante.

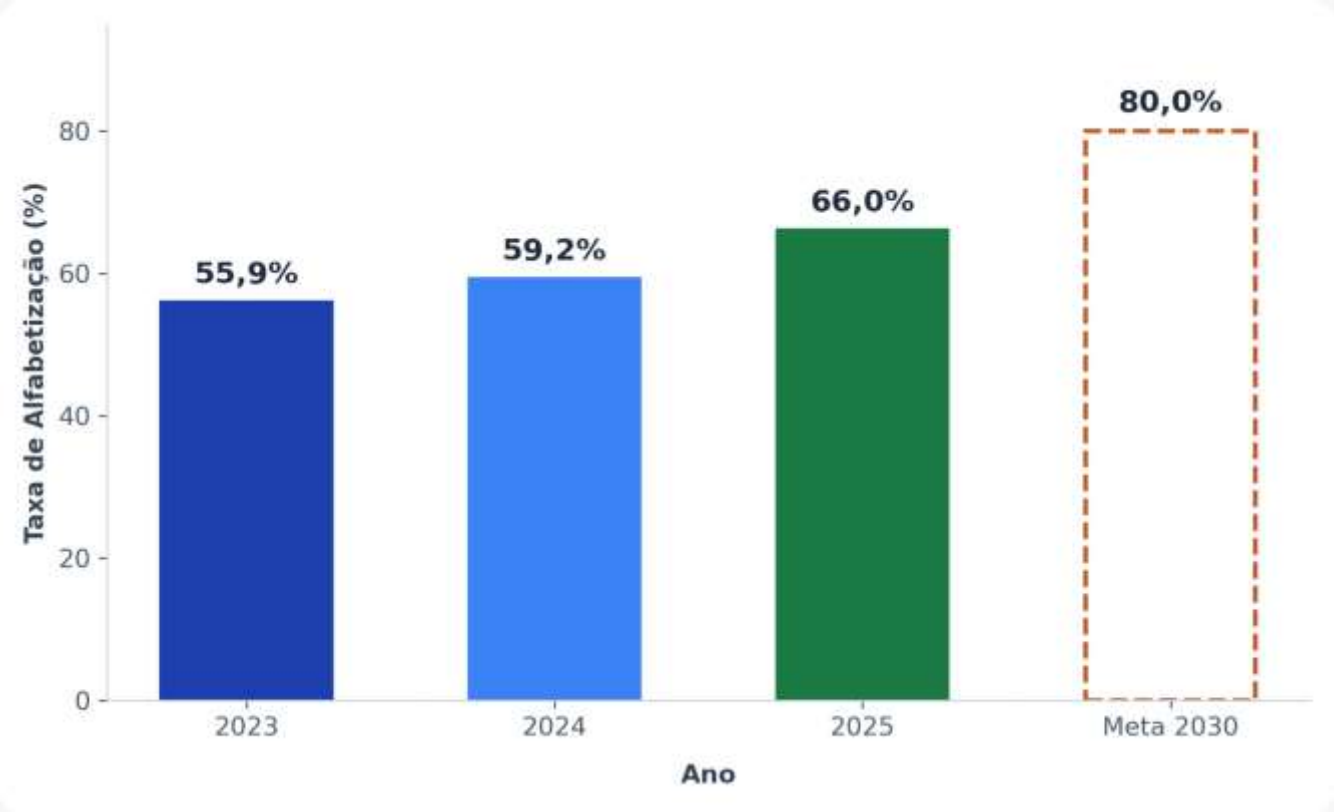
LOGS E ALERTAS EM TEMPO REAL

RESPOSTA A FALHAS

Erros são registrados em logs e no BigQuery; notificações de falha são disparadas por e-mail ao responsável em menos de um minuto, garantindo resposta imediata.



EVOLUÇÃO NO BRASIL (2023–2025)



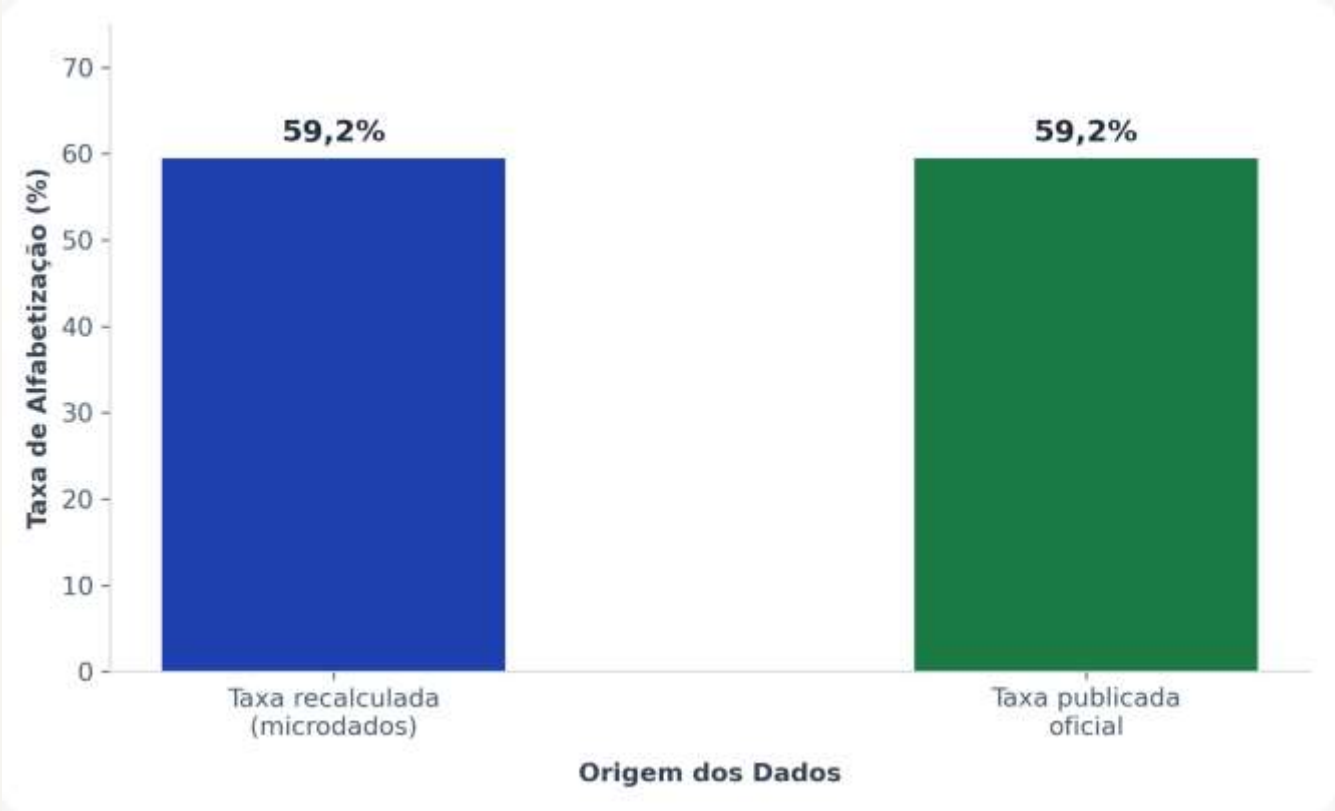
+10,1 p.p.

de evolução entre 2023 e 2025 na rede pública

14 p.p.

ainda faltam para atingir a meta de 80% em 2030

VALIDAÇÃO INTEGRAL DE MICRODADOS



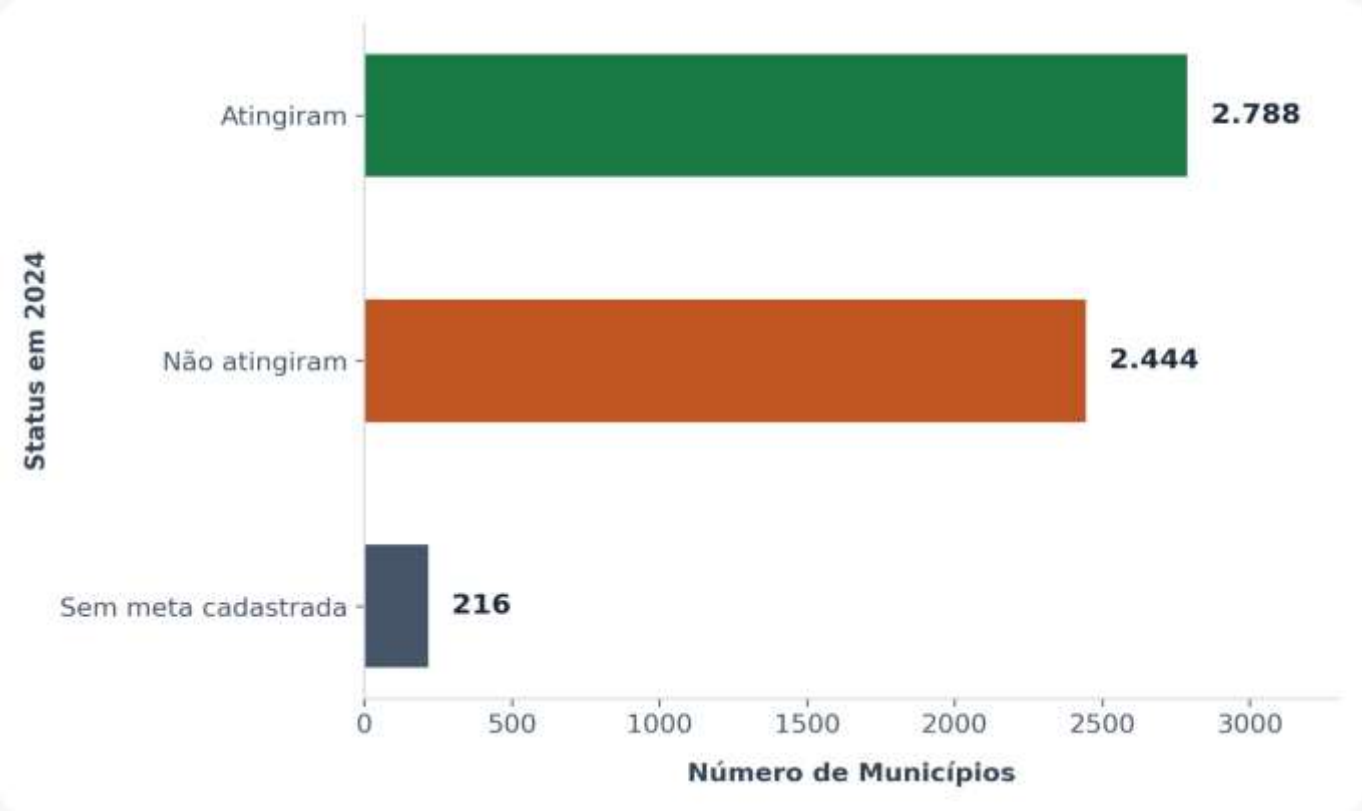
141 de 144

recortes UF/rede com desvio inferior a 0,5 p.p.

3,9 MILHÕES

de registros processados com soma correta de pesos amostrais

CUMPRIMENTO DAS METAS NOS MUNICÍPIOS



53,3%

dos municípios com meta cumpriram o patamar exigido em 2024

Sem meta ≠ falha

isolar os sem meta cadastrada evita falsos negativos na avaliação

GOVERNANÇA TÉCNICA E CUSTO PREVISÍVEL

IA / FASE 3

Tabela gold_features_fase3 pronta para o modelo preditivo.

GOVERNANÇA ANTIVAZAMENTO

Regra anti data leakage estrita: utiliza apenas dados do ano anterior (t−1).

STREAMING & FINOPS

Processamento via Pub/Sub com deduplicação por lote. Custo atual de R$ 0,00 (Sandbox) e projeção de ~US$ 12/mês.

R$ 0,00

Sandbox ativo

0,89 s

mediana de latência do streaming (produtor → consumidor)

09 CONCLUSÃO E IMPACTO PRÁTICO

TRANSFORMANDO DADOS EM AÇÃO PARA A ALFABETIZAÇÃO

1

Radiografia Nacional

Evolução de 55,9% para 66% e visibilidade dos abismos regionais entre as UFs.

2

Apoio Direto aos Municípios

Separação cirúrgica entre quem atingiu, quem não atingiu e quem estava sem meta cadastrada, evitando falsos negativos.

3

Prevenção Antecipada via IA

Capacidade de antecipar riscos para que o poder público atue de forma preventiva.

Obrigado!

Pipeline Híbrido para Análise da Alfabetização no Brasil

Henrique Carvalho Brod · Iuri de Jesus Martins · Nathalia Vilas Boas · Patrícia Terezinha Marques Borba